

## I. Pen-and-paper

### Primeira pergunta:

Four positive observations,  $\left\{\begin{pmatrix} A \\ 0 \end{pmatrix}, \begin{pmatrix} B \\ 1 \end{pmatrix}, \begin{pmatrix} A \\ 1 \end{pmatrix}, \begin{pmatrix} A \\ 0 \end{pmatrix}\right\}$ , and four negative observations,  $\left\{\begin{pmatrix} B \\ 0 \end{pmatrix}, \begin{pmatrix} B \\ 0 \end{pmatrix}, \begin{pmatrix} A \\ 1 \end{pmatrix}, \begin{pmatrix} B \\ 1 \end{pmatrix}\right\}$ , were collected. Consider the problem of classifying observations as positive or negative.

- 1) [4v] Compute the recall of a distance-weighted  $k$ NN with  $k = 5$  and distance  $d(\mathbf{x}_1, \mathbf{x}_2) = \text{Hamming}(\mathbf{x}_1, \mathbf{x}_2) + \frac{1}{2}$  using leave-one-out evaluation schema (i.e., when classifying one observation, use all remaining ones).

### Resposta:

$$\text{Recall} = \frac{\text{true positive}}{\text{true positive} + \text{false negative}}.$$

Observações positivas:

$$\left\{\begin{pmatrix} A \\ 0 \end{pmatrix}, \begin{pmatrix} B \\ 1 \end{pmatrix}, \begin{pmatrix} A \\ 1 \end{pmatrix}, \begin{pmatrix} A \\ 0 \end{pmatrix}\right\}$$

Observações negativas:

$$\left\{\begin{pmatrix} B \\ 0 \end{pmatrix}, \begin{pmatrix} B \\ 0 \end{pmatrix}, \begin{pmatrix} A \\ 1 \end{pmatrix}, \begin{pmatrix} B \\ 1 \end{pmatrix}\right\}$$

Conjunto total das observações:  $\{x_1, x_2, \dots, x_8\}$

Número de features: 2  $\{y_1, y_2\}$

Class output: 2  $\{P, N\}$

Nota:

	$y_1$	$y_2$	out
x1	A	0	P
x2	B	1	P
x3	A	1	P
x4	A	0	P
x5	B	0	N
x6	B	0	N
x7	A	1	N
x8	B	1	N

### Def:

Hamming( $X_1, X_2$ ) representa o número de entradas distintas entre  $X_1$  e  $X_2$

Exemplo:

$$X_1 = (A, 0)$$

$$X_2 = (B, 1)$$

$$\text{Hamming}(X_1, X_2) = 2$$

## Aprendizagem 2021/22

### Homework I – Group 081

Parametros de avaliação;

Distance-weighted,kNN with  $k = 5$  and  $\text{distance}(x_i, x_j) = \text{Hamming}(x_i, x_j) + \frac{1}{2}$

Nota: O  $\frac{1}{2}$  permite o calculo do peso no fim das contas evitando a divisão por 0.

$\text{Weight} = 1/\text{distance}$

#### Avaliar distância x1:

##### Positivos:

$$\text{Dis}(x1, x2) = 2 + \frac{1}{2}$$

$$\text{Dis}(x1, x3) = 1 + \frac{1}{2}$$

$$\text{Dis}(x1, x4) = 0 + \frac{1}{2}$$

##### Negativos:

$$\text{Dis}(x1, x5) = 1 + \frac{1}{2}$$

$$\text{Dis}(x1, x6) = 1 + \frac{1}{2}$$

$$\text{Dis}(x1, x7) = 1 + \frac{1}{2}$$

$$\text{Dis}(x1, x8) = 2 + \frac{1}{2}$$

#### Avaliar peso x1 para os 5 com menos distância:

##### Positivos:

$$w(x1, x3) = 1 / (1 + \frac{1}{2})$$

$$w(x1, x4) = 1 / (0 + \frac{1}{2})$$

##### Negativos:

$$w(x1, x5) = 1 / (1 + \frac{1}{2})$$

$$w(x1, x6) = 1 / (1 + \frac{1}{2})$$

$$w(x1, x7) = 1 / (1 + \frac{1}{2})$$

$$P: (2/3 + 2) = 8/3$$

$$N: (3 * 2/3) = 6/3$$

Concluimos que segundo estes parametros de avaliação x1 terá classe P (o que vai de acordo com as observações)

Como isto se verifica P será considerado um “True positive”

Iremos agora repetir o mesmo para todos os x's

Chegaremos às seguintes conclusões:

	kNN out	Obsevado	Classificação
x1	P	P	TP
x2	N	P	FN
x3	N	P	FN
x4	P	P	TP
x5	N	N	TN
x6	N	N	TN
x7	N	N	TN
x8	N	N	TN

#### Conclusões:

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

$$\text{Recall} = 2 / 4 = 0.5$$

**Segunda pergunta:**

An additional positive observation was acquired,  $\begin{pmatrix} B \\ 0 \end{pmatrix}$ , and a third variable  $y_3$  was independently monitored, yielding estimates  $y_3|P = \{1.2, 0.8, 0.5, 0.9, 0.8\}$  and  $y_3|N = \{1, 0.9, 1.2, 0.8\}$ .

- 2) [4v] Considering the nine training observations, learn a Bayesian classifier assuming:
- i)  $y_1$  and  $y_2$  are dependent, ii)  $\{y_1, y_2\}$  and  $\{y_3\}$  variable sets are independent and equally important, and ii)  $y_3$  is normally distributed. Show all parameters.

**Resposta:**

**Objetivo:** Mostrar todos os parametros necessários para aprender o “Bayesian classifier”

$$P(P | y_1, y_2, y_3) = \frac{P(P) * P(y_1, y_2, y_3 | P)}{P(y_1, y_2, y_3)}$$

Trivial:

$$P(P) = 5/9$$

Menos simples:

$$>>> P(y_1, y_2, y_3 | P)$$

Dado que os subconjuntos  $\{y_1, y_2\}$  e  $\{y_3\}$  são independentes entre si podemos dizer que:

$$P(y_1, y_2, y_3 | P) = P(y_1, y_2 | P) * P(y_3 | P)$$

$$>> P(y_1, y_2 | P)$$

Conjunto discreto [ALL COMBINATIONS]:

$$P(A, 0 | P) = 2/5$$

$$P(A, 1 | P) = 1/5$$

$$P(B, 0 | P) = 1/5$$

$$P(B, 1 | P) = 1/5$$

(estes valores derivam de observação direta)

$$>> P(y_3 | P)$$

Conjunto contínuo [NORMAL DISTRIBUTION]

$$P(y_3 | P) = N(y_3 | \text{mean}, DP^2)$$

$$\text{Mean} = \frac{1.2 + 0.8 + 0.5 + 0.9 + 0.8}{5} = 0.84$$

$$DP = [...] = \text{sqrt}(0.063) \text{ (calculated using rstudio)}$$

>>>  $P(y_1, y_2, y_3)$ : Este valor terá o mesmo valor tanto em  $P(P | y_1, y_2, y_3)$  como em  $P(N | y_1, y_2, y_3)$  por isso não terá importância para o objetivo pedido.

Aprendizagem 2021/22  
**Homework I – Group 081**

Precisamos ainda de parametros semelhantes mas agora para:

$$P(N | y_1, y_2, y_3) = \frac{P(N) * P(y_1, y_2, y_3 | N)}{P(y_1, y_2, y_3)}$$

Trivial:

$$P(N) = 4/9$$

Menos simples:

>>>  $P(y_1, y_2, y_3 | N)$

Dado que os subconjuntos  $\{y_1, y_2\}$  e  $\{y_3\}$  são independentes entre si podemos dizer que:

$$P(y_1, y_2, y_3 | N) = P(y_1, y_2 | N) * P(y_3 | N)$$

>>  $P(y_1, y_2 | N)$

Conjunto discreto [ALL COMBINATIONS]:

$$P(A, 0 | N) = 0$$

$$P(A, 1 | N) = 1/4$$

$$P(B, 0 | N) = 1/2$$

$$P(B, 1 | N) = 1/4$$

(estes valores derivam de observação direta)

>>  $P(y_3 | N)$

Conjunto continuo [NORMAL DISTRIBUTION]

$$P(y_3 | N) = N(y_3 | \text{mean}, DP^2)$$

$$\text{Mean} = \frac{1+0.9+1.2+0.8}{4} = \text{sqrt}(0.975)$$

$$DP = [...] = 0.02917 \text{ (calculated using rstudio)}$$

>>>  $P(y_1, y_2, y_3)$ : Este valor terá o mesmo valor tanto em  $P(P | y_1, y_2, y_3)$  como em  $P(N | y_1, y_2, y_3)$  por isso não terá importância para o objetivo pedido

Todos os parametros que precisamos foram devidamente calculados.

### **Terceira pergunta:**

Considering three testing observations,  $\left\{ \left( \begin{pmatrix} A \\ 1 \\ 0.8 \end{pmatrix}, \text{Positive} \right), \left( \begin{pmatrix} B \\ 1 \\ 1 \end{pmatrix}, \text{Positive} \right), \left( \begin{pmatrix} B \\ 0 \\ 0.9 \end{pmatrix}, \text{Negative} \right) \right\}$ .

3) [3v] Under a MAP assumption, compute  $P(\text{Positive} | \mathbf{x})$  of each testing observation.

---

**Resposta:**

Geral:

$$\frac{P(P) * P(y1, y2, y3 | P)}{P(y1, y2, y3)}$$

Nota: Média das observações:  
0.9Desvio padrão das observações:  
0.2179**Parte 1: P(y1=A,y2=1,y3=0.8 | Positive)**

$$\begin{aligned} \frac{P(P) * P(y1=A, y2=1, y3=0.8 | P)}{P(y1=A, y2=1, y3=0.8)} &= \frac{\left(\frac{5}{9}\right) * P(y1 = A, y2 = 1 | P) * P(y3=0.8 | P)}{P(y1=A, y2=1) * P(y3=0.8)} = \\ &= \frac{\left(\frac{5}{9}\right) * \frac{1}{5} * N(0.8 | 0.84, \sqrt{0.063})}{\frac{2}{9} * N(0.8 | 0.9, 0.2179)} = [...] = 0.4763 \text{ (calculado usando o rstudio)} \end{aligned}$$

**Parte 2: P(y1=B,y2=1,y3=1 | Positive)**

$$\begin{aligned} \frac{P(P) * P(y1=B, y2=1, y3=1 | P)}{P(y1=B, y2=1, y3=1)} &= \frac{\left(\frac{5}{9}\right) * P(y1 = B, y2 = 1 | P) * P(y3=1 | P)}{P(y1=B, y2=1) * P(y3=1)} = \\ &= \frac{\left(\frac{5}{9}\right) * \frac{1}{5} * N(1 | 0.84, \sqrt{0.063})}{\frac{2}{9} * N(1 | 0.9, 0.2179)} = [...] = 0.3937 \text{ (calculado usando o rstudio)} \end{aligned}$$

**Parte 3: P(y1=B,y2=0,y3=0.9 | Positive)**

$$\begin{aligned} \frac{P(P) * P(y1=B, y2=0, y3=0.9 | P)}{P(y1=B, y2=0, y3=0.9)} &= \frac{\left(\frac{5}{9}\right) * P(y1 = B, y2 = 0 | P) * P(y3=0.9 | P)}{P(y1=B, y2=0) * P(y3=0.9)} = \\ &= \frac{\left(\frac{5}{9}\right) * \frac{1}{5} * N(0.9 | 0.84, \sqrt{0.063})}{\frac{3}{9} * N(0.9 | 0.9, 0.2179)} = [...] = 0.2813 \text{ (calculado usando o rstudio)} \end{aligned}$$

Conclusão:

Todas as probabilidades P(Positive|x) foram calculadas com sucesso

**Quarta pergunta:**

4) [2v] Given a binary class variable, the default decision threshold of  $\theta = 0.5$ ,

$$f(\mathbf{x}|\theta) = \begin{cases} \text{Positive} & P(\text{Positive}|\mathbf{x}) > \theta \\ \text{Negative} & \text{otherwise} \end{cases}$$

can be adjusted. Which decision threshold – 0.3, 0.5 or 0.7 – optimizes testing accuracy?

---

**Resposta:**

$$\text{Accuracy} = (\text{TP} + \text{TN}) / \text{ALL}$$

$$X1 = (A, 1, 0.8) \quad X2 = (B, 1, 1) \quad X3 = (B, 0, 0.9)$$

Threshold of 0.3

1.  $P(P|X1) = 0.476$ , segundo este threshold dá Positivo, o seu valor também é positivo ou seja é um TP
2.  $P(P|X2) = 0.39$ , segundo este threshold dá Positivo, o seu valor também é positivo ou seja é um TP
3.  $P(P|X3) = 0.28$ , segundo este threshold dá Negativo, o seu valor também é negativo ou seja é um TN

$$\text{Accuracy} = 3/3 = 100\%$$

Threshold of 0.5 e 0.7

1.  $P(P|X1) = 0.476$ , segundo este threshold dá Negativo, o seu valor é positivo ou seja é um FP
2.  $P(P|X2) = 0.39$ , segundo este threshold dá Negativo, o seu valor é positivo ou seja é um FP
3.  $P(P|X3) = 0.28$ , segundo este threshold dá Negativo, o seu valor também é negativo ou seja é um TN


$$\text{Accuracy} = 1/3 = 33.(3)\%$$

Conclusão:

Neste contexto o Threshold que maximizava os nossos resultados era o de 0.3

## II. Programming and critical analysis

- 5) [3v] Using `sklearn`, considering a 10-fold stratified cross validation (`random=0`), plot the cumulative testing confusion matrices of  $k$ NN (uniform weights,  $k = 5$ , Euclidean distance) and Naïve Bayes (Gaussian assumption). Use all remaining classifier parameters as default.



- 6) [2v] Using `scipy`, test the hypothesis “ $k$ NN is statistically superior to Naïve Bayes regarding accuracy”, asserting whether is true.

**0.9104476998751558**

Usando estatística (ttest)

Chegamos ao valor p: 0.91

$0.91 > 0.05$

Desta forma concluímos que a afirmação “ $k$ NN is statistically superior to Naive Bayes regarding accuracy” não pode ser demonstrada usando os nossos dados.

- 7) [2v] Enumerate three possible reasons that could underlie the observed differences in predictive accuracy between  $k$ NN and Naïve Bayes.

As diferenças na precisão dos métodos poderá ser causada por:

- 1 ) As features poderão ser pouco dependentes favorecendo bastante a precisão do naïve bayes.
- 2 ) No geral o Naïve bayes é muito preciso quando trabalhamos com big data, o tamanho de `pd_speech.arff` poderá ter interferido nos resultados.
- 3 ) O valor de  $k$  escolhido para o  $k$ NN poderá não ter sido o mais indicado para o problema

### III. APPENDIX

Pergunta 5

```
from matplotlib import pyplot as plt
from scipy.io.arff import loadarff
from sklearn import metrics, tree
from sklearn.model_selection import PredefinedSplit, train_test_split
from sklearn.feature_selection import SelectKBest, mutual_info_classif
from sklearn.model_selection import StratifiedKFold
from sklearn.naive_bayes import GaussianNB
from sklearn.neighbors import KNeighborsClassifier
import pandas as pd
import seaborn as sns

# Reading the ARFF file
data = loadarff('pd_speech.arff')
df = pd.DataFrame(data[0])
df['class'] = df['class'].str.decode('utf-8')

# Split in data and targets
X = df.drop('class', axis=1)
y = df['class']

# Define Labels
labels = list(set(y))

# FOLDS: 10
skf = StratifiedKFold(n_splits=10, random_state=0, shuffle=True)

# KNN (5, uniform, euclidean)
neigh = KNeighborsClassifier(n_neighbors=5)
df = pd.DataFrame()
df_compare = pd.DataFrame()

# NAIVE
gnb = GaussianNB()
naive_df = pd.DataFrame()

for train_index, test_index in skf.split(X, y):
    neigh.fit(X.iloc[train_index], y.iloc[train_index])
    predictor = neigh.predict(X.iloc[test_index])
    df = pd.concat([df, pd.DataFrame(predictor)])
    df_compare = pd.concat([df_compare, pd.DataFrame(y.iloc[test_index])])
```



Aprendizagem 2021/22  
Homework I – Group 081

```
naive_df = pd.concat([naive_df, pd.DataFrame(gnb.fit(X.iloc[train_index],
y.iloc[train_index]).predict(X.iloc[test_index]))])

cm = metrics.confusion_matrix(df_compare, df, labels=labels)
cm_display =
metrics.ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=labels)
cm_display.plot()
cm_display.ax_.set_title("KNN [Results]")

cm = metrics.confusion_matrix(df_compare, naive_df, labels=labels)
cm_display =
metrics.ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=labels)
cm_display.plot()
cm_display.ax_.set_title("Naive [Results]")
```

Pergunta 6

```
import imp
from re import A
from matplotlib import pyplot as plt
from scipy.io.arff import loadarff
from sklearn import metrics, tree
from sklearn.model_selection import PredefinedSplit, train_test_split
from sklearn.feature_selection import SelectKBest, mutual_info_classif
from sklearn.model_selection import StratifiedKFold
from sklearn.naive_bayes import GaussianNB
from scipy import stats
from sklearn.neighbors import KNeighborsClassifier
import pandas as pd
import seaborn as sns

# Reading the ARFF file
data = loadarff('pd_speech.arff')
df = pd.DataFrame(data[0])
df['class'] = df['class'].str.decode('utf-8')

# Split in data and targets
X = df.drop('class', axis=1)
y = df['class']

# Define labels
labels = list(set(y))

# FOLDS: 10
```

```
skf = StratifiedKFold(n_splits=10,random_state=0,shuffle=True)

# BASE
df_compare = pd.DataFrame()

# KNN (5,uniform,euclidean)
neigh = KNeighborsClassifier(n_neighbors=5)
knn_df = pd.DataFrame()

# NAIVE
gnb = GaussianNB()
naive_df = pd.DataFrame()

knn_accs = []
naive_accs = []

for train_index,test_index in skf.split(X,y):
    neigh.fit(X.iloc[train_index],y.iloc[train_index])
    predictor = neigh.predict(X.iloc[test_index])
    knn_df = pd.concat([knn_df,pd.DataFrame(predictor)])
    df_compare = pd.concat([df_compare,pd.DataFrame(y.iloc[test_index])])

    naive_predictor = gnb.fit(X.iloc[train_index],
y.iloc[train_index]).predict(X.iloc[test_index])
    naive_df = pd.concat([naive_df,pd.DataFrame(naive_predictor)])

    knn_acc = metrics.accuracy_score(y.iloc[test_index],predictor)
    naive_acc = metrics.accuracy_score(y.iloc[test_index],naive_predictor)

    knn_accs.append(knn_acc)
    naive_accs.append(naive_acc)

var = stats.ttest_rel(knn_accs,naive_accs,alternative="greater")
print(var.pvalue)

# Pvalue = 0.91
# 0.91 > 0.05 negamos a afirmação (a accuracy de knn nao é maior)
```

END